

LLM Hallucination 사전 탐지 및 인코딩 메커니즘 분석

딥러닝 팀 프로젝트 종합 보고서

팀원: wclee, kcai (+ Budchar 팀)

작성일: 2026-05-14

데이터셋: TriviaQA, NQ-Open, SQuAD, CommonsenseQA (각 n=200-1,000)

목차

1. 서론
 2. 연구 방법
 3. 핵심 가설 검증 결과
 4. 실험 결과 — Self-Consistency 재현 및 Calibration 분석
 5. 실험 결과 — SE / SEPs / Self-Consistency (대규모)
 6. 실험 결과 — 레이어 인코딩 위치 및 메커니즘
 7. 통합 분석: 두 접근법의 교차 해석
 8. 종합 논의
 9. 결론
 10. 참고문헌
-

1. 서론

대형 언어 모델(LLM)은 사실과 다른 내용을 자신 있게 생성하는 **Hallucination** 문제를 보인다. 본 연구는 이 현상을 두 가지 상보적 관점에서 분석한다.

관점 A — 확률적 불일치 탐지: 동일 질문에 대한 여러 샘플 간의 의미적 불일치(Semantic Entropy)와 hidden state 기반 사전 예측(SEPs)을 통해 생성 전 hallucination을 탐지할 수 있는가?

관점 B — 표현 기하학적 메커니즘: 트랜스포머 레이어 내부의 어느 위치에서, 어떤 서브모듈(MLP / Attention)이 hallucination을 인코딩하는가? Fine-tuning 방법이 이 위치를 결정하는가?

핵심 연구 질문:

- RQ1: SEPs는 Semantic Entropy 대비 비용 효율적으로 hallucination을 탐지할 수 있는가?

- RQ2: Hallucination 신호가 집중되는 레이어 위치는 어디이며, 모델마다 왜 다른가?
- RQ3: Fine-tuning 방법(SFT 데이터 유형, DPO)이 인코딩 위치와 주체를 결정하는가?

2. 연구 방법

2.1 실험 모델

[관점 A] Semantic Entropy 분석 대상

모델	파라미터	비고
Llama-3.2-1B-Instruct	1B	Meta
Llama-3.2-3B-Instruct	3B	Meta
Qwen2.5-1.5B-Instruct	1.5B	Alibaba
Qwen2.5-3B-Instruct	3B	Alibaba
Qwen2.5-7B-Instruct	7B	Alibaba
Pythia-70M ~ 6.9B	70M-6.9B	EleutherAI (스케일링 분석)
OLMo, GPT-Neo-1.3B, OPT-1.3B, TinyLlama	~1.3B	패밀리 비교

[관점 B] 레이어 메커니즘 분석 대상

모델	학습 방식	Best Layer	AUROC
Mistral-7B-v0.1 (BASE)	사전학습만	L29 (91%)	0.789
Mistral-7B-Instruct-v0.2	SFT	L21 (66%)	0.615
OpenHermes-2.5	SFT (사실 Q&A)	L21 (66%)	0.795
Zephyr-7B-beta	SFT + DPO	L15 (47%)	0.559
OpenChat-3.5	C-RLFT	L16 (50%)	0.868
Starling-LM-7B-alpha	C-RLFT + RLHF	L32 (100%)	0.664
NousHermes-2-DPO	사실SFT + DPO	L2 (6%)	0.806
Mistral-7B-Instruct-v0.3	사실SFT + DPO	L4 (12%)	0.808
EXAONE-3.5-7.8B	독자 학습	L30 (94%)	0.838
Qwen2.5-7B-Instruct	SFT	L22 (79%)	0.821
Phi-3-mini-4k	SFT	L18 (56%)	0.774

2.2 방법론

Semantic Entropy (SE) (Farquhar et al., 2024): 동일 질문에 N=10회 샘플링 → entailment 모델로 의미적 동치 클러스터 분류 → 클러스터 분포의 Shannon entropy 계산. 높은 SE = 높은 불확실성.

Self-Consistency (SC) (Wang et al., 2023): N=10 샘플의 다수결 답변 선택. 불확실성이 낮을 때 정확도 향상 기대.

Semantic Entropy Probes (SEPs) (Kossen et al., 2024): 각 레이어의 last-token hidden state로 로지스틱 회귀/MLP 분류기를 학습하여 단일 forward pass로 SE를 예측. 비용 1/N.

Layer Probe (Exp06): 레이어별 hidden state에 로지스틱 회귀(C=1.0)를 독립 학습, AUROC로 hallucination 탐지 능력 측정. Best Layer = AUROC 최고점.

Sublayer Probe (Exp12): 각 레이어를 두 지점으로 분리:

- `attn_stream[i]` = 레이어 입력 + Attention 출력 (MLP 이전)
- `mlp_stream[i]` = 전체 레이어 출력 (MLP 이후)

두 스트림의 AUROC를 비교하여 인코딩 주체를 판별.

Logit Lens (Exp11): 중간 hidden state를 LM head에 통과시켜 레이어별 vocab 분포 entropy 추적.

2.3 평가 지표

- **AUROC**: 탐지 성능 주지표 (0.5=무작위, 1.0=완벽)
 - **ECE** (Expected Calibration Error): 신뢰도 보정 평가
 - **Brier Score**: 확률 예측 정확도
 - **AURC** (Area Under Risk-Coverage): threshold별 정확도-커버리지
 - **Cost Saving**: Adaptive SE의 샘플링 비용 절감율
-

3. 핵심 가설 검증 결과

[관점 A] SE / SEPs / SC 가설

가설	내용	결과	핵심 수치
H-A1	고SE 구간에서 SC가 정확도를 낮춘다	부분 통과	소형 모델(1B-3B) 고SE 구간 SC 적용 시 가중평균 변화 -0.0206
H-A2	SEPs가 SE 대비 우위	통과	평균 AUROC 격차 $+0.065$; 모델 크기 클수록 격차 감소 ($r=-0.53$, $p=0.041$)
H-A3	할루시네이션 신호 peak가 중후반 레이어에서 나타남	조건부 통과 (H3-revised)	Standard SFT/Instruct 그룹: 0.682 ± 0.131 (원래 H3 재현); 전체 80셀: 0.49 ± 0.31 (범용성 기각 후 그룹 조건화)
H-A4	Adaptive SE로 비용 절감 가능	부분 통과	평균 절감율 18.8% (목표 30% 미달); Qwen-7B/TriviaQA 42.8%

[관점 B] 레이어 메커니즘 가설

가설	내용	결과	핵심 수치
H-B1	Layer probe로 hallucination 사전 탐지 가능	통과	11개 모델 중 8개 AUROC > 0.75 ; OpenChat-3.5 최고 0.868
H-B2	Fine-tuning 방법이 인코딩 레이어를 결정	통과	동일 SFT + DPO 추가 $\rightarrow$ best layer L21 $\rightarrow$ L2 (-19 layers)
H-B3	Type I = MLP 주도, Type II = Attention 주도	통과	NousHermes MLP-Attn gap $+0.160$; EXAONE gap -0.079
H-B4	Logit Lens로 Type I/II 패턴 구분 가능	부분 통과	Type I: 조기 entropy 수렴; Type II: 후반 지속 성장 확인

4. 실험 결과 — Self-Consistency 재현 및 Calibration 분석

4.0 실험 개요

모델: Qwen2.5-0.5B-Instruct | 데이터셋: CommonsenseQA validation (200문제) | N=10, T=0.7, 7-shot CoT

Wang et al.(2023)의 Self-Consistency를 소형 모델에서 재현하고, 다수결의 부산물인 consistency rate를 confidence proxy로 평가했다.

4.1 정확도: SC vs Greedy

방법	정확도	답 추출 성공률
Greedy (N=1, T=0)	50.5%	47.5%
Self-Consistency (N=10, T=0.7)	52.8%	99.5%

+2.2pp 정확도 향상. 그러나 더 주목할 점은 **추출 성공률**: Greedy는 절반의 응답에서 답 형식을 만들지 못했으나, SC의 다양한 샘플링이 답 형식 robustness를 자연스럽게 확보했다.

원 논문(PaLM-540B, GSM8K)의 +17.9pp와 비교하면 작은 향상 — 0.5B + 객관식 환경의 한계이다.

4.2 Consistency Rate → Correctness Calibration

AUROC = 0.664 (H-SC2 통과)

Consistency rate 구간별 실제 정답률:

Consistency Rate 구간	n	실제 정답률
0.0 - 0.2	12	~50% (이상치, n 부족)
0.2 - 0.4	약 80	40%
0.4 - 0.7	약 90	69%
0.7 - 1.0	18	83%
1.0 (완전 일관)	~9	100%

단조 증가 패턴 확인: 일관성이 높을수록 정답일 가능성이 높다. 0.5B 소형 모델에서도 SC가 의미 있는 confidence estimator로 동작함을 보여준다.

4.3 0.5B 모델의 한계: 신호 분리력 부족

- Consistency rate **평균 = 0.34** (N=10 중 평균 3.4개만 같은 답)
- rate ≥ 0.7 인 케이스: 전체의 **4.5%** (9개/199개)
- 모델이 "확신하는" 경우 자체가 드물어 high-confidence 영역이 매우 좁음

SC calibration은 유효하지만 **0.5B에서는 신호 분리력이 낮다**. 모델이 너무 작으면 항상 불일치하고, 너무 크면 항상 일치하는 trade-off가 있다.

4.4 SC Calibration vs Semantic Entropy

방법	핵심 아이디어	AUROC	비용
SC Consistency Rate	표면 문자열 일치율	0.664	N번 생성
Semantic Entropy	의미 클러스터 entropy	(Phase1 결과)	N번 생성 + entailment
SEPs	hidden state → SE 예측	+0.065 vs SE	1번 생성

SC(0.664)는 의미 기반 SE의 하한선에 해당하는 **baseline calibrator**이다. SE가 표면 매칭의 한계를 의미 클러스터링으로 극복한 이유가 이 baseline에서 드러난다.

5. 실험 결과 — SE / SEPs / Self-Consistency

5.0 H3의 진화: 범용 가설 → 조건부 정제

H3는 본 연구에서 가장 풍부하게 발전한 가설이다. 세 단계를 거쳐 최종 형태에 도달했다.

[1단계] 원래 H3 — 5개 Instruct 모델 (Phase 1)

Llama-3.2-1B/3B + Qwen2.5-1.5B/3B/7B 5개 모델 측정 결과:

peak 상대 깊이 평균 0.68 ± 0.12 → "Universal한 패턴"으로 가설 수립

[2단계] H3 기각 — 80셀 확장 (v2 Sweep)

Pythia 스케일링 + from-scratch + TinyLlama 포함 총 80셀로 확장:

전체 평균 0.49 ± 0.31 → 분산 폭발, H3 범용성 기각

[3단계] H3-revised — 학습 방법별 그룹 분석

80셀을 학습 방법으로 분류해 재분석:

그룹	n	평균	std
Standard SFT/Instruct	15	0.682	0.131
BASE (사전학습만)	39	0.588	0.223
Pythia 학습 trajectory	13	0.426	0.272
From-scratch (degenerate)	10	0.549	0.260
TinyLlama intermediate	3	0.515	0.175

Mann-Whitney U test: $p = 0.007$ — 그룹 간 차이 통계적 유의

핵심: Standard SFT/Instruct 그룹(n=15)에서 원래 H3 수치(0.68 ± 0.12)가 **정확히 재현**된다. H3는 범용 법칙이 아니라 **표준 Instruct fine-tuning 모델에 한정된 조건부 패턴**이다.

[두 팀 결과의 결합]

wclee의 Mistral 7B 8변형 분석이 위 그룹 차이의 메커니즘을 설명한다:

학습 방법	Best L	상대 깊이	그룹 귀속
BASE	L29	91%	BASE 그룹
SFT (일반) / SFT (사실) / SFT+DPO / C-RLFT	L15-L21	47-66%	Standard SFT ✓
C-RLFT + RLHF	L32	100%	RLHF outlier
사실SFT + DPO (NousHermes, Mistral-v0.3)	L2-L4	6-12%	Type I (early, 이탈)

Standard SFT 그룹 평균(47-66%)이 팀의 0.682와 일치한다. Type I 이탈 모델은 DPO+사실SFT 조합으로 분리된다.

최종 H3-revised 발견문 (main contribution 후보):

"환각 신호의 peak 상대 깊이는 표준 SFT/Instruct 학습된 LLM에서 0.65-0.70에 robust하게 위치하나, 학습 방법(BASE, DPO+factual SFT, RLHF, from-scratch)이 이 위치를 결정적으로 변동시킨다. 이는 fine-tuning이 hallucination 인코딩 위치를 결정한다는 mechanistic 발견(Sublayer Probe + Logit Lens)과 정확히 일관된다."

5.1 SE vs SEPs 성능 비교

15셀(5개 모델 × 3개 데이터셋, 각 n=1,000) 전체 분석 결과:

SEPs가 SE보다 평균 +0.065 AUROC 우위 (H-A2 통과)

모델	AUROC(SE)	AUROC(SEPs)	Gap
Llama-3.2-1B	낮음	높음	가장 큰 격차
Llama-3.2-3B	중간	높음	큰 격차
Qwen2.5-1.5B	중간	높음	큰 격차
Qwen2.5-3B	중간-높음	높음	중간 격차
Qwen2.5-7B	높음	높음	역전(-0.010)

스케일링 패턴: 모델이 클수록 SEPs 우위가 줄어든다 ($r=-0.53$, $p=0.041$). Qwen-7B에서는 SE가 SEPs를 오히려 앞섬. **소형 모델에서 SEPs 실용 가치가 가장 크다.**

4.2 Self-Consistency와 Semantic Entropy의 상호작용

H-A1 부분 통과: SC는 불확실성이 낮을 때(저SE 구간)만 효과적이다.

- Q1 (저SE): SC 적용 시 정확도 변화 ≈ 0 (중립)
- Q3 (고SE): SC 적용 시 가중평균 정확도 변화 **-0.0206** (소형 모델 기준)
- 대형 모델(7B 이상): 고SE 구간에서도 SC가 이득을 줄 수 있음

실무 함의: 소형 모델(1B-3B)에서는 SE를 먼저 측정하고, 고SE 입력에는 SC를 적용하지 않는 Adaptive 전략이 필요하다.

4.3 Confident-but-Wrong 분석

소형 모델(SQuAD 기준):

- 73-85%의 오답 케이스에서 모델이 **높은 신뢰도**(top-quartile confidence)를 보임
- SE는 이를 사전에 탐지하지 못하는 경우 존재
- SEPs는 같은 케이스에서 SE보다 낮은 신뢰도 점수를 부여하는 경향

4.4 Adaptive SE 비용 절감

H-A4 부분 통과: 평균 18.8% 비용 절감, 목표 30% 미달.


모델/데이터셋	비용 절감율	정확도 손실
Qwen-7B / TriviaQA	42.8%	최소
기타 평균	18.8%	미미

모델 규모와 데이터 난이도가 높을수록 Adaptive SE 효율이 증가한다.

5. 실험 결과 — 레이어 인코딩 위치 및 메커니즘

5.1 레이어별 AUROC: 모델마다 다른 인코딩 위치

Mistral 아키텍처 8개 변형 비교 (동일 아키텍처, 학습 방식만 다름):



H-A3과의 관계: 팀 관점 A의 peak depth 0.68 ± 0.12 는 Type II 모델(일반 SFT 계열) 기반이다. Type I 모델(DPO+사실SFT)을 포함하면 분포가 **이중봉(bimodal)**으로 나타난다.

5.2 Fine-tuning이 인코딩 위치를 결정한다 (H-B2)

단계별 원인 추적:

단계	가설	모델	결과	결론
1	아키텍처?	Mistral-BASE	L29	✗ 아님
2	일반 SFT?	Mistral-v0.2	L21	✗ 아님
3	DPO만?	Zephyr (UltraChat+DPO)	L15	✗ 아님
4	사실성 데이터만?	OpenHermes (DPO없음)	L21	✗ 아님
5	사실성 SFT + DPO?	NousHermes	L2	✓ 확인

결정적 증거: OpenHermes(SFT only, L21, AUROC=0.795) vs NousHermes(동일 SFT + DPO, L2, AUROC=0.806) — 유일한 차이는 DPO 적용 여부. best layer가 **L21 → L2로 -19 layers 이동**.

사실성 밀도가 높은 SFT 데이터(OpenHermes: GPT-4 생성 사실 Q&A ~1M건)가 필요조건이고, DPO가 이 회로를 초반 MLP에 고착시키는 충분조건이다.

5.3 Sublayer Probe: MLP vs Attention 인코딩 주체 (H-B3)

모델	Best Layer	Attn AUROC	MLP AUROC	Gap(MLP-Attn)	주체	유형
NousHermes-DPO	L2	0.646	0.806	+0.160	MLP	Type I
Mistral-v0.3	L4	0.776	0.808	+0.032	MLP	Type I
Mistral-BASE	L29	0.741	0.762	+0.021	Both	Type II
OpenHermes	L21	0.758	0.783	+0.025	Both	Type II
Qwen2.5-7B	L22	0.798	0.812	+0.014	Both	Type II
EXAONE-3.5	L30	0.917	0.838	-0.079	Attention	Type II-Attn

EXAONE 특이점: L15 attn_stream AUROC=0.917이 full-layer best(L30=0.838)보다 높다.
Attention 메커니즘이 L15에서 이미 더 집중된 신호를 형성하고 있음.

5.4 인코딩 유형 분류 체계

Type I – Early MLP (Best layer ≤ 5 , MLP dominant)

조건: 사실성 SFT 데이터 + DPO

모델: Mistral-7B-Instruct-v0.3 (L4), NousHermes-2-DPO (L2)

특징: L2-4의 MLP stream이 hallucination 신호 주도

Logit Lens: 초반 레이어에서 vocab entropy 조기 수렴

Type II – Late (Best layer > 15)

Type II-Both: MLP + Attention 공동 인코딩

모델: Mistral-BASE (L29), OpenHermes (L21), Qwen2.5-7B (L22)

Type II-Attn: Attention 주도

모델: EXAONE-3.5 (L30, gap=-0.079)

Type II-RLHF: RLHF로 인해 마지막 레이어로 밀림

모델: Starling-LM-7B-alpha (L32, 100%)

특징: RLHF가 DPO와 반대 방향으로 best layer를 이동

5.5 Logit Lens: Vocab Entropy 성장 패턴 (H-B4)

중간 레이어의 hidden state를 LM head에 통과시킨 vocab entropy 분석:

- **Type I 모델 (Mistral-v0.3):** L4 이후 entropy 차이(정답 vs 오답 토큰)가 조기 수렴. 초반에서 이미 사실 판별이 완료됨.
- **Type II 모델 (EXAONE, Qwen):** 후반 레이어까지 entropy 차이가 지속 성장. 레이어가 깊어질수록 vocab 불확실성 신호가 강해짐.

6. 통합 분석: 두 접근법의 교차 해석

6.1 Peak Depth 재해석

구분	Peak Depth	해당 모델
팀 관점 A 전체 평균	0.68 ± 0.12	Llama, Qwen 계열 (5개)
관점 B — Type II	0.47 ~ 1.00 (평균 ≈ 0.72)	일반 SFT 모델들
관점 B — Type I	0.06 ~ 0.12	사실SFT + DPO 모델들

팀의 0.68 ± 0.12 는 Type II 모델만 반영한 수치다. Type I 모델을 포함하면 전체 분포는 0.06-1.00으로 분산되며, **fine-tuning 방법이 이 분포의 결정 변수임을** 알 수 있다.

6.2 SEPs 레이어 선택 전략 개선 가능성

팀 관점 A의 SEPs는 레이어별 probe를 학습한다. 관점 B의 발견을 적용하면:

- **Type I 모델**에서는 초반 L2-4만 탐침해도 충분한 신호 확보 → SEPs 비용 추가 절감 가능
- **Type II 모델**에서는 0.6-0.8 깊이 구간에 집중하는 전략 유효
- Type 분류 자체를 zero-shot으로 판별하는 **Meta-SEPs** 가능성 제시

6.3 모델 크기 vs Fine-tuning 방법

변수	팀 관점 A 발견	관점 B 발견
모델 크기	SEPs 우위가 크기에 따라 감소 ($r=-0.53$)	—
Fine-tuning 방법	—	동일 7B 규모에서 AUROC 0.559~0.868 분산
종합 해석	모델 크기가 탐지 용이성에 영향	Fine-tuning 방법이 더 강한 예측 변수

7B 동일 규모에서 fine-tuning 방법만으로 AUROC 범위가 0.559(Zephyr)~0.868(OpenChat) — 이 분산이 모델 크기 효과보다 크다.

6.4 SC 역효과와 인코딩 유형의 관계

팀 관점 A: 소형 모델 고SE 구간에서 SC가 역효과 (-0.0206).

관점 B: Starling-LM(RLHF, L32)처럼 후반 레이어 의존 모델은 샘플 간 불일치가 크다.

RLHF가 best layer를 마지막(L32)으로 밀어내는 현상은, 동일 입력에 대해 모델이 후반부까지 처리해야 최종 판단을 내림을 의미한다. 이는 N=10 샘플 간 분산을 높여 SC가 불안정해지는 원인이 될 수 있다.

7. 종합 논의

7.1 LLM은 생성 전 이미 "틀릴 것"을 알고 있는가?

예, 단 모델마다 다른 레이어에서, 다른 방식으로.

- SE/SEPs (관점 A): 여러 샘플의 의미적 불일치로 간접 측정 → 소형 모델에서 유효
- Layer Probe (관점 B): 단일 forward pass의 hidden state로 직접 측정 → AUROC 0.75-0.87 달성

두 방법 모두 생성 전 탐지가 가능함을 확인했다. 단, **SEPs와 Layer Probe는 본질적으로 같은 현상의 두 가지 관측 방법**이다: SEPs가 SE를 예측하도록 학습된 probe를, Layer Probe는 정답/오답 레이블로 직접 학습한다.

7.2 메커니즘: MLP Key-Value Memory와 DPO

초반 MLP 레이어가 사실 지식을 key-value 쌍으로 저장하는 구조를 가진다는 Geva et al.(2021)의 발견을 기반으로:

1. **사실성 SFT (OpenHermes)**: GPT-4가 생성한 고밀도 사실 Q&A 학습이 초반 MLP key-value 회로를 강화.
2. **DPO**: "이 답이 맞다/틀리다"는 선호 신호가 이 회로를 조기 활성화하도록 파라미터를 업데이트.
3. **결과**: L2-4에서 이미 "이 답은 틀릴 것"이라는 표현이 형성됨.

일반 대화 데이터(UltraChat) + DPO(Zephyr)는 이 효과가 없다 — 사실 지식의 밀도 자체가 조건이다.

7.3 실용적 탐지 전략 제안

상황	권장 방법	근거
소형 모델 (1B-3B), 비용 제약	SEPs (초반 레이어)	관점 A: 가장 큰 SE-SEPs 격차
Type I 모델 (사실SFT+DPO)	Layer Probe L2-4 만	관점 B: 초반에 신호 집중
Type II 모델 (일반 SFT)	SEPs (60-80% 구간)	관점 A/B 일치: peak 0.68
고불확실 입력	SE만 계산, SC 미적용	관점 A: SC가 역효과
Adaptive 비용 절감	Qwen-7B급: Adaptive SE	관점 A: 42.8% 절감

8. 결론

본 팀 프로젝트는 LLM hallucination 사전 탐지를 확률적 불일치(SE/SEPs)와 표현 기하학적 메커니즘(Layer/Sublayer Probe) 두 관점에서 종합 분석했다.

주요 결론:

결론 1 (탐지 방법론): SEPs는 Semantic Entropy 대비 평균 +0.065 AUROC 우위이며, 소형 모델에서 효과가 가장 크다. 단, Self-Consistency는 고SE 구간 소형 모델에서 역효과(-0.0206)를 낳는다.

결론 2 (레이어 위치): Hallucination 신호 peak는 평균 상대 깊이 0.68에 위치하나, fine-tuning 방법에 따라 0.06~1.00의 이중봉 분포를 보인다.

결론 3 (메커니즘): 사실성 SFT 데이터(OpenHermes) + DPO 조합이 hallucination 인코딩을 후반 레이어(L21)에서 초반 MLP(L2-4)로 이동시킨다. NousHermes vs OpenHermes (동일 SFT, DPO 유무만 다름)가 이를 직접 증명했다.

결론 4 (인코딩 주체): Type I 모델(초반 MLP)과 Type II 모델(후반 Attention/Both)로 분류되며, 이는 fine-tuning 레시피에 의해 결정된다.

한계: SE 계산의 높은 비용(N=10 샘플링), Layer Probe의 모델별 fine-tuning 필요, Logit Lens 분석의 추가 모델 검증 부족. 향후 연구에서 Type 분류 자동화 및 더 다양한 아키텍처 검증이 필요하다.

9. 참고문헌

- Wang, X. et al. (2023). Self-Consistency Improves Chain of Thought Reasoning in Language Models. ICLR 2023. <https://arxiv.org/abs/2203.11171>
- Farquhar, S. et al. (2024). Detecting Hallucinations in Large Language Models Using Semantic Entropy. Nature, 630, 625-630. <https://doi.org/10.1038/s41586-024-07421-0>
- Kossen, J. et al. (2024). Semantic Entropy Probes: Robust and Cheap Hallucination Detection in LLMs. NeurIPS 2024. <https://arxiv.org/abs/2406.15927>
- Geva, M. et al. (2021). Transformer Feed-Forward Layers Are Key-Value Memories. EMNLP 2021. <https://arxiv.org/abs/2012.14913>
- Rafailov, R. et al. (2023). Direct Preference Optimization: Your Language Model is Secretly a Reward Model. NeurIPS 2023. <https://arxiv.org/abs/2305.18290>
- nostalgebraist (2020). Interpreting GPT: The Logit Lens. LessWrong. <https://www.lesswrong.com/posts/AckRB8wDpdaN6v6ru>

- **Gu, Y. et al. (2025).** When Attention Sink Emerges in Language Models: An Empirical View. ICLR 2025 Spotlight. <https://arxiv.org/abs/2410.10781>
- **Xu (2026).** Early-Warning Signals of Grokking via Loss-Landscape Geometry. <https://arxiv.org/abs/2602.16967>